

Modelos Predictivos en Negocios

Manual científico y técnico para la docencia

Yerko Carreño Pérez

2026-10-08

Tabla de contenidos

Propósito, alcance y forma de uso	2
0.1 Ruta intensiva de cinco semanas	3
0.2 Objetivos y evidencias por módulo	3
1 El problema predictivo	4
1.1 De la decisión a $Y = f(X) + \varepsilon$	4
1.2 Error reducible e irreducible	4
1.3 Línea base y fuga de información	5
2 Técnicas y aplicaciones en negocios	5
2.1 Familias de modelos	5
2.2 Aplicaciones sectoriales y sus límites	6
2.3 Explicar sin tecnicismos	6
2.4 Red neuronal: principio con un cálculo transparente	6
3 CRISP-DM y preparación de datos	7
3.1 Fases con entregables	7
3.2 Calidad de datos y mecanismos de vacíos	7
3.3 Partición y pipeline	7
4 Regresión	7
4.1 Estimación por mínimos cuadrados	7
4.2 Estacionalidad e ingeniería de variables	8
4.3 Diagnóstico y regularización	8
4.4 Predicciones con intervalo	8
5 Clasificación	8
5.1 Regresión logística	8
5.2 Árboles, bosques y vecinos	9
6 Validación y selección de modelos	9
6.1 Esquemas de validación	9
6.2 Hiperparámetros y complejidad	9
7 Métricas de evaluación	9
7.1 Regresión	9
7.2 Clasificación y ordenamiento	10
7.3 Ejemplo: lectura crítica de métricas	10
8 Umbral, costos y calibración	10
8.1 El umbral como decisión económica	10
8.2 Calibración	11
8.3 Eventos raros	11
9 Limitaciones, estabilidad y gobierno del modelo	12
9.1 Dónde puede fallar un modelo	12
9.2 Estabilidad poblacional	12
9.3 Riesgo de modelo y obligaciones	12

10	Comunicación y mejora continua	12
10.1	Ficha del modelo	12
10.2	Mensajes por audiencia	12
10.3	Recomendaciones de mejora	13
10.4	Lectura crítica de informes	13
11	Profundización: pronóstico de series de tiempo	13
12	Ejercicios resueltos y preguntas de discusión	13
13	Rúbrica formativa y ruta de doce semanas	14
13.1	Rúbrica formativa de un proyecto predictivo	14
13.2	Ruta sugerida	14
14	Glosario	15
	Referencias	16
	Bibliografía	16

Propósito, alcance y forma de uso

Este manual desarrolla el recorrido completo de un modelo predictivo en una organización: desde la decisión que se quiere mejorar hasta la comunicación de resultados, sus límites y su monitoreo. Integra formulación matemática, supuestos, ejemplos calculados con los casos docentes del repositorio y criterios para discutir resultados. Es material propio; no reemplaza el programa oficial de ningún curso.

Resultados de aprendizaje. El material se organiza en tres resultados y quince criterios de evaluación. La tabla indica su distribución en una ruta extendida de doce semanas; la ruta intensiva de cinco semanas se presenta a continuación.

RA	Resultado de aprendizaje	Criterios	Semanas
RA1	Explica las técnicas principales del modelamiento predictivo, con ejemplos en contextos de negocio	CE 1.1–1.4	1–2
RA2	Construye modelos predictivos simples con datos históricos y software especializado	CE 2.1–2.6	3–7
RA3	Evalúa la efectividad de los modelos con métricas clave para proponer mejoras	CE 3.1–3.5	8–12

Tres recursos complementarios. La guía maestra interactiva sirve para explicar y experimentar en clase; este manual desarrolla fundamentos y supuestos; los siete notebooks permiten inspeccionar y modificar cada cálculo. Las tablas y figuras de este documento se recalculan al renderizarlo, con las mismas funciones que usan los notebooks.

Qué significa rigor en esta asignatura. No depende del número de algoritmos. Exige formular la decisión, comprobar que cada variable exista al momento de predecir, separar datos para aprender, decidir y evaluar, comparar contra una línea base, declarar supuestos de costo, cuantificar incertidumbre y comunicar límites. Un modelo simple que cumple esas condiciones vale más que uno sofisticado que no las cumple.

Ruta	Alcance	Evidencia de aprendizaje
Núcleo U1	Problema predictivo, técnicas, aplicaciones y límites	Formulación defendible y explicación sin tecnicismos

Ruta	Alcance	Evidencia de aprendizaje
Núcleo U2	CRISP-DM, preparación, regresión y clasificación	Modelo funcional, validado y comparado con una línea base
Núcleo U3	Métricas, umbral, costos, calibración, limitaciones y comunicación	Evaluación honesta, ficha del modelo y recomendaciones
Profundización	Validación temporal, pronóstico, recalibración, riesgo de modelo	Discusión de supuestos y diseño de validación

Convenciones. FinCordillera, QuillayMarket y PulpaLenga son empresas ficticias con datos simulados del repositorio. Los costos son supuestos docentes declarados. «Entrenamiento», «validación» y «prueba» designan conjuntos con funciones distintas que nunca se intercambian.

0.1 Ruta intensiva de cinco semanas

En la ruta intensiva, RA1 ocupa las semanas 1–2, RA2 las semanas 3–4 y RA3 la semana 5. Se introduce temprano una métrica para que cada entrenamiento tenga un propósito. Usar FinCordillera para clasificación y QuillayMarket para regresión reduce cambios de contexto. Las series temporales quedan como profundización: el criterio CE2.3 admite regresión lineal o series, y la ruta prioriza el entrenamiento de regresión.

Semana	Núcleo de la sesión	Evidencia y notebook
1	Diagnóstico Python, objetivo, clasificación/regresión y referencia	NB01: contrato, línea base y fuga
2	Lineal simple/múltiple, logística, árbol y fundamento de red neuronal	NB01 técnicas/red; NB03 MCO y NB04 logística/árbol como demostración. Evaluación 1
3	CRISP-DM, limpieza, partición, selección de algoritmo y clasificación	NB02 y NB04: pipeline, entrenamiento y sobreajuste
4	Matriz de confusión, métricas, validación y costos	NB05: métricas y umbral. Evaluación 2
5	Entrenamiento de regresión, MAE/RMSE/R ² , límites y comunicación	NB03 y NB06: comparación, ficha y mejoras. Evaluación 3

No exigir leer los siete notebooks completos antes de la primera sesión. Seleccionar los bloques enlazados por la ruta; regularización, conformal, recalibración avanzada, PSI y pronóstico se consultan después del núcleo. El manual conserva las explicaciones técnicas para referencia. La ruta no comprime mecánicamente doce semanas en cinco: prioriza el núcleo.

El fundamento de redes neuronales cubre la explicación pedida en CE1.1; entrenar una red profunda no se agrega como obligación. Las ponderaciones y fechas de evaluación corresponden a cada curso.

0.2 Objetivos y evidencias por módulo

Preparación de entrada: Python básico, tablas, probabilidad e interpretación de regresión; diagnóstico en NB01.

Los tiempos orientan una práctica guiada y deben ajustarse al diagnóstico del grupo. Cada módulo sigue la secuencia: anticipar → ejecutar → modificar → explicar. La profundización se consulta después del núcleo.

NB01 · Problema predictivo (Núcleo). Definir objetivo, horizonte, disponibilidad de variables y referencia. **Evidencia:** Entregar ficha de problema, referencia y justificación de una técnica; explicar la red mínima.

NB02 · Preparación sin fuga (Núcleo). Construir un pipeline que aprenda transformaciones solo con entrenamiento. **Evidencia:** Demostrar separación de datos, contrato de variables y transformaciones ajustadas sin prueba.

NB03 · Regresión de demanda (Núcleo). Comparar regresión y alternativas con referencia e incertidumbre de predicción. **Evidencia:** Reportar MAE/RMSE, referencia, diagnóstico y diferencia entre IC de media e intervalo predictivo.

NB04 · Clasificación de abandono (Núcleo). Evaluar discriminación y una campaña con probabilidades y costos explícitos. **Evidencia:** Justificar modelo y política con métricas fuera de muestra y límites de utilidad.

NB05 · Validación, métricas y umbral (Núcleo). Seleccionar modelo y umbral sin reutilizar la prueba para decidir. **Evidencia:** Documentar selección, datos reservados y costo; no inferir calibración por coincidencia de umbrales.

NB06 · Limitaciones y comunicación (Núcleo). Construir una ficha de modelo con seguimiento, responsables y condiciones de uso. **Evidencia:** Entregar ficha con evidencia, incertidumbre, umbral de revisión y propuesta de mejora.

NB07 · Pronóstico de demanda (Profundización). Evaluar una serie mediante orígenes móviles y referencias comparables. **Evidencia:** Explicar horizonte, cobertura observada, referencia y límites de cambios del proceso.

1 El problema predictivo

1.1 De la decisión a $Y = f(X) + \varepsilon$

Un modelo predictivo supone que un resultado de negocio Y se relaciona con información disponible X :

$$Y = f(X) + \varepsilon, \quad E[\varepsilon | X] = 0, \quad \text{Var}(\varepsilon) = \sigma^2.$$

f es desconocida y se estima con datos históricos. Antes de cualquier algoritmo se declaran cinco elementos: la **variable objetivo** (qué se predice y cómo se mide), la **unidad** (qué representa una fila), el **horizonte** (cuánto antes se predice), la **decisión** que cambia con la predicción y el **costo** de cada tipo de error. Una formulación incompleta produce modelos técnicamente correctos que no se pueden usar.

1.2 Error reducible e irreducible

Para un estimador $\hat{f}$ y una observación nueva en x , el error cuadrático esperado se descompone en

$$E[(Y - \hat{f}(x))^2] = (f(x) - E[\hat{f}(x)])^2 + \text{Var}(\hat{f}(x)) + \sigma^2.$$

El primer término es el **sesgo** al cuadrado (el modelo es demasiado rígido), el segundo la **varianza** (el modelo cambia mucho con la muestra) y el tercero el **error irreducible**. Figura 1 lo muestra con un mecanismo simulado: el error en entrenamiento baja siempre al aumentar la complejidad; el de observaciones nuevas baja y luego sube, y nunca cruza de forma sostenida el piso σ^2 .




Figura 1: Simulación con mecanismo conocido (demanda curva según precio, $\sigma = 12$). El error en entrenamiento disminuye con el grado; en datos nuevos aparece el compromiso sesgo–varianza. La línea discontinua es σ^2 .

1.3 Línea base y fuga de información

Una **línea base** es la regla más simple razonable: clase mayoritaria, promedio histórico o «el mismo mes del año anterior». Un modelo aporta valor solo si la supera en la métrica que importa y en datos no usados para aprender. En FinCordillera, declarar que nadie abandona logra una accuracy de 72% sin detectar ningún caso: accuracy no puede ser la métrica guía cuando la decisión trata del evento minoritario.

Una **fuga de información** ocurre cuando el modelo usa datos que no existirán al decidir: variables registradas después del evento, totales que incluyen el futuro o transformaciones ajustadas con todos los datos. Su síntoma es un desempeño excelente en validación y un fracaso en operación [1]. La prueba práctica es preguntar, para cada variable, cuándo se registra y quién la registra.

2 Técnicas y aplicaciones en negocios

2.1 Familias de modelos

Técnica	Principio	Fortalezas	Limitaciones
Regresión lineal	$\hat{y} = \beta_0 + x^\top \beta$ por mínimos cuadrados	Interpretable, rápida, referencia obligada	Supone forma lineal; sensible a extremos
Regresión logística	Modela $\log \frac{p}{1-p}$ como función lineal	Probabilidades y razones de chances	Fronteras lineales salvo transformaciones
Árbol de decisión	Particiones recursivas que reducen impureza	Reglas legibles, no linealidades	Alta varianza; inestable
Bosque aleatorio	Promedio de árboles con remuestreo	Buen desempeño con poco ajuste	Menos explicable; calibración variable
KNN	Promedio de los k casos más cercanos	Sin forma funcional	Depende de la escala y de la dimensión
Redes neuronales	Composición de transformaciones no lineales	Patrones complejos con muchos datos	Datos, cómputo y explicabilidad exigentes

Técnica	Principio	Fortalezas	Limitaciones
Series de tiempo	Tendencia, estacionalidad y dependencia temporal	Respeto el orden del tiempo	Supone estabilidad del proceso

La elección se justifica por el tipo de Y , el volumen de datos, la necesidad de explicar cada decisión a un cliente o regulador y el costo de los errores; no por popularidad [2], [3].

2.2 Aplicaciones sectoriales y sus límites

Sector	Problema	Tipo	Límite que conviene declarar
Banca	Abandono, fraude, riesgo de crédito	Clasificación	Eventos raros, sesgo por segmento, regulación
Retail	Demanda por categoría y mes	Regresión / series	Estacionalidad, promociones, quiebres de stock
Industria	Defectos por lote, consumo energético	Clasificación / regresión	Cambios de materia prima o sensores
Recursos humanos	Rotación voluntaria	Clasificación	Variables sensibles y decisiones sobre personas
Salud	Reingresos, demanda de camas	Clasificación / series	Consecuencias graves de falsos negativos

Un modelo **reduce** incertidumbre; no la elimina. Supone que el futuro se parece al pasado en lo relevante y que los datos representan a la población sobre la que se decidirá. Cuando esas condiciones cambian —una pandemia, un nuevo competidor, otro proveedor— el modelo debe revisarse.

2.3 Explicar sin tecnicismos

Una explicación para audiencias no técnicas declara qué decisión mejora, en cuánto y con qué incertidumbre. «El modelo tiene AUC 0,80» no es un mensaje; «si contactamos al 20% de clientes con mayor riesgo, alcanzamos cerca de 40% de los abandonos del período» sí lo es. Conviene evitar términos sin traducir, mostrar una sola cifra clave por idea y anticipar la pregunta «¿y si cambia la situación?».

2.4 Red neuronal: principio con un cálculo transparente

Una red compone transformaciones: $h = \text{ReLU}(W_1x + b_1)$ y $p = \sigma(\langle w_2, h \rangle + b_2)$. ReLU devuelve $\max(0, z)$ y la sigmoide transforma un puntaje en un número entre cero y uno. En aprendizaje supervisado los pesos se ajustan minimizando una pérdida, por ejemplo entropía cruzada para una etiqueta binaria, mediante gradientes y regularización. La composición permite fronteras no lineales; también agrega parámetros y riesgo de sobreajuste.

En el notebook 01, dos entradas docentes escaladas (reclamos y antigüedad) pasan por dos unidades ocultas con pesos fijados expresamente. Para $x = (0, 0)$, sesgos ocultos $(-.2, .1)$, pesos de salida $(1.5, -.8)$ y sesgo final $-.5$, resulta $h = (0, .1)$ y $p = \sigma(-.58) \approx .359$. Es una demostración de propagación, **no un modelo entrenado ni una probabilidad bancaria validada**. Mover las entradas permite observar qué cambia y qué permanece.

Una aplicación posible es priorizar revisión de clientes con patrones de interacción complejos. Antes de elegir una red se compara con logística o árbol usando el mismo diseño de validación, escala aprendida solo en entrenamiento y métricas de negocio. Más capas no garantizan más valor; tamaño de datos, costo, estabilidad, calibración y explicabilidad condicionan la elección. Explíquelo a gerencia como combinaciones de señales aprendidas, no como una imitación literal del cerebro.

3 CRISP-DM y preparación de datos

3.1 Fases con entregables

CRISP-DM organiza un proyecto en seis fases iterativas: comprensión del negocio, comprensión de los datos, preparación, modelamiento, evaluación y despliegue [4]. Su valor práctico aparece cuando cada fase deja un **entregable revisable** y un **criterio de salida**: ficha del problema, contrato de datos, pipeline, comparación contra línea base, informe de evaluación y plan de monitoreo.

3.2 Calidad de datos y mecanismos de vacíos

Mecanismo	Definición	Consecuencia	Tratamiento
MCAR	El vacío no depende de nada	Pérdida de eficiencia, sin sesgo	Imputación simple con estadísticos de entrenamiento
MAR	Depende de variables observadas	Sesgo en casos completos	Imputación condicional e indicador de vacío
MNAR	Depende del valor faltante	Sesgo que los datos no pueden corregir solos	Indicador, fuente alternativa y declaración del sesgo

Los valores extremos se clasifican antes de tratarlos: un error de digitación se corrige en origen; un extremo legítimo se conserva y, si conviene, se transforma. La mediana es robusta a extremos; la media no.

3.3 Partición y pipeline

Se usan tres conjuntos con funciones distintas: **entrenamiento** para ajustar parámetros y transformaciones, **validación** para comparar modelos y elegir hiperparámetros, umbral y costos, y **prueba** para una única evaluación final. Con pocos datos, la validación cruzada de k pliegues dentro del entrenamiento sustituye a una validación fija. Si los datos tienen orden temporal se particiona por tiempo; si una entidad aparece varias veces, por grupos.

Toda transformación aprendida de los datos —imputación, escalamiento, selección de variables— se ajusta **dentro** de un pipeline, con las filas de entrenamiento de cada pliegue. Seleccionar variables con todas las filas y luego validar produce desempeños ficticios incluso con ruido puro [5, sección 7.10.2].

4 Regresión

4.1 Estimación por mínimos cuadrados

Con X de dimensión $n \times p$ (incluida la columna de unos), el estimador de mínimos cuadrados ordinarios es

$$\hat{\beta} = (X^T X)^{-1} X^T y, \quad \widehat{\text{Var}}(\hat{\beta}) = \hat{\sigma}^2 (X^T X)^{-1}, \quad \hat{\sigma}^2 = \frac{\sum_i e_i^2}{n - p}.$$

Cada coeficiente es el cambio esperado en Y por unidad de la variable, **manteniendo las demás constantes** y en el rango observado. No es un efecto causal salvo diseño experimental. Las variables categóricas entran como indicadores con una categoría de referencia.

Tabla 1: QuillayMarket · regresión de unidades vendidas estimada con entrenamiento. Precio en miles de CLP y marketing en cientos de miles; categoría de referencia: Alimentos.

	coeficiente	error estándar	t	p
intercepto	238.347	4.844	49.200	0.000
mes	3.669	0.325	11.284	0.000
promocion_activa	32.508	2.334	13.930	0.000
categoria_producto_Electrohogar	10.921	6.951	1.571	0.117
categoria_producto_Tecnologia	33.426	9.529	3.508	0.001
categoria_producto_Vestuario	7.026	5.062	1.388	0.166
precio_miles	-8.548	0.525	-16.293	0.000
marketing_100mil	4.773	0.448	10.650	0.000

4.2 Estacionalidad e ingeniería de variables

Representar el mes como número supone una recta de enero a diciembre. Con indicadores por mes, el modelo estima un nivel propio para cada mes y capta el alza de noviembre y diciembre. Tabla 2 compara ambas especificaciones en validación: una variable bien representada mejora más que un algoritmo más complejo.

Tabla 2: QuillayMarket · validación. Mes como número frente a mes como categoría.

	MAE	RMSE	R2	sesgo_medio	MAPE_%
mes como número	15.45	19.59	0.89	0.61	9.90
mes como categoría	13.20	15.91	0.93	-1.20	8.32

4.3 Diagnóstico y regularización

Los residuos de un buen modelo no muestran estructura respecto de la predicción, el tiempo o los grupos. La normalidad importa para intervalos paramétricos, no para la calidad predictiva.

Con muchas variables correlacionadas, la regularización estabiliza los coeficientes. Ridge minimiza $\sum_i (y_i - x_i^\top \beta)^2 + \alpha \sum_j \beta_j^2$ y encoge todos los coeficientes; Lasso usa la penalización $\alpha \sum_j |\beta_j|$ y puede anular algunos, lo que equivale a seleccionar variables. Las variables se estandarizan antes de penalizar y α se elige con validación cruzada en entrenamiento [2, capítulo 6].

4.4 Predicciones con intervalo

Una predicción puntual sin rango invita a decisiones frágiles. El **intervalo conformal dividido** usa los residuos absolutos de un conjunto de calibración: con q igual a su cuantil de orden $\lceil (n+1)(1-\alpha) \rceil / n$, el intervalo $\hat{y} \pm q$ cubre al menos $1 - \alpha$ de casos nuevos **intercambiables** con los de calibración, si el modelo se mantiene fijo [6]. No protege contra extrapolación ni cambios del proceso, y su cobertura debe verificarse en prueba. Si el modelo se reestima después de calcular el cuantil, la garantía deja de aplicarse exactamente; el notebook 03 informa la cobertura observada junto con su error estándar.

5 Clasificación

5.1 Regresión logística

$$\log \frac{p(x)}{1-p(x)} = \beta_0 + x^\top \beta, \quad p(x) = \frac{1}{1 + e^{-(\beta_0 + x^\top \beta)}}.$$

e^{β_j} es la **razón de chances**: el factor por el que se multiplican las chances del evento cuando x_j sube una unidad, con lo demás fijo. Si la probabilidad base es 20% (chances 0,25) y la razón de chances es 2, las chances pasan a 0,5 y la probabilidad a 33%, no a 40%.

5.2 Árboles, bosques y vecinos

Un árbol elige en cada nodo la división que más reduce la impureza; con el índice de Gini, $G = 1 - \sum_k p_k^2$. Es legible e inestable. Un bosque promedia árboles entrenados con muestras bootstrap y subconjuntos de variables, lo que reduce varianza. KNN predice con los k vecinos más cercanos: sin estandarizar, la variable de mayor escala domina la distancia. Para interpretar modelos complejos se prefiere la **importancia por permutación** medida en validación.

Tabla 3: FinCordillera · comparación en validación de modelos ajustados con entrenamiento.

	AUC	Gini	KS	AP	Brier
Línea base (prevalencia)	0.500	0.000	0.000	0.279	0.201
Logística	0.715	0.429	0.353	0.507	0.178
KNN sin escalar	0.429	-0.141	0.094	0.243	0.218
KNN estandarizado	0.691	0.382	0.312	0.435	0.184
Bosque aleatorio	0.680	0.359	0.379	0.435	0.185

La logística compite con el bosque y es explicable: con relaciones mayoritariamente monótonas, un modelo simple bien especificado es difícil de superar. KNN sin escalar casi no supera al azar porque el ingreso domina la distancia.

6 Validación y selección de modelos

6.1 Esquemas de validación

Esquema	Cuándo usarlo	Riesgo si se usa mal
Entrenamiento / validación / prueba	Datos suficientes; decisiones de umbral y costos	Validación pequeña produce decisiones ruidosas
k pliegues estratificados	Comparar especificaciones con su variabilidad	Fugas si la preparación ocurre fuera del pipeline
Validación anidada	Estimar el desempeño del procedimiento completo de selección	Costo computacional
Origen móvil	Datos temporales	Una partición aleatoria mezcla pasado y futuro
Por grupos	Una entidad con varias filas	Optimismo por filas casi repetidas

Una diferencia entre modelos menor que la desviación estándar entre pliegues no justifica preferir uno por desempeño: deciden la interpretabilidad, el costo de operación o la robustez.

6.2 Hiperparámetros y complejidad

Los hiperparámetros (profundidad, C , α , k) se eligen con búsqueda en grilla y validación cruzada dentro del entrenamiento. La brecha entre el desempeño de entrenamiento y el de validación es una señal compatible con sobreajuste; también puede deberse a particiones distintas o deriva. Un modelo que no supera a la línea base no debe pasar a la fase de evaluación.

7 Métricas de evaluación

7.1 Regresión

Métrica	Definición	Lectura
MAE	$\frac{1}{n} \sum y_i - \hat{y}_i $	Error típico en unidades; robusto
RMSE	$\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$	Penaliza errores grandes

Métrica	Definición	Lectura
R^2	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Comparación con la media; puede ser negativo fuera de muestra
MAPE	$\frac{100}{n} \sum (y_i - \hat{y}_i)/y_i $	Indefinido con ceros; asimétrico
Sesgo	$\frac{1}{n} \sum (\hat{y}_i - y_i)$	Error sistemático: comprar de menos o de más

7.2 Clasificación y ordenamiento

Con la matriz de confusión (VP, FP, FN, VN): precisión = $\frac{VP}{VP+FP}$, recall = $\frac{VP}{VP+FN}$ y $F_1 = \frac{2PR}{P+R}$. Accuracy engaña con clases desbalanceadas. Las métricas que no dependen del umbral describen el **ordenamiento**: ROC-AUC es la probabilidad de que un positivo reciba mayor puntaje que un negativo; la precisión promedio (AP) resume la curva precisión-recall y su referencia es la prevalencia, por lo que es más informativa con eventos raros [7]. En riesgo de crédito se usan KS —máxima distancia entre las distribuciones acumuladas de puntaje de positivos y negativos— y Gini = $2 \text{AUC} - 1$ [8]. El puntaje de Brier $\frac{1}{n} \sum (p_i - y_i)^2$ evalúa la calidad de las probabilidades.

7.3 Ejemplo: lectura crítica de métricas

Quince casos ficticios con valores reales y predichos permiten practicar la lectura de métricas. Tabla 4 calcula las métricas habituales y agrega el sesgo, que suele omitirse.

Tabla 4: Quince casos ficticios · métricas de ventas y de abandono.

métrica	valor
MAE	29.800
RMSE	32.045
R^2	0.933
sesgo medio	-29.800
precisión abandono	1.000
recall abandono	0.286

El R^2 es alto, pero las quince predicciones de ventas están bajo el valor real: el sesgo llevaría a comprar menos inventario del necesario. En abandono, la precisión perfecta convive con un recall bajo. Ninguna métrica aislada describe el desempeño.

8 Umbral, costos y calibración

8.1 El umbral como decisión económica

Un clasificador probabilístico **ordena**; el umbral convierte el orden en acción. Sean c_{FN} y c_{FP} los costos de un falso negativo y de un falso positivo. Si la probabilidad p está calibrada, actuar tiene un costo esperado $(1 - p) c_{FP}$ y no actuar $p c_{FN}$. Conviene actuar cuando

$$p > t^* = \frac{c_{FP}}{c_{FP} + c_{FN}},$$

un resultado clásico del aprendizaje sensible a costos [9]. En PulpaLenga, con $c_{FN} = 800$ y $c_{FP} = 90$ miles de CLP, $t^* \approx 0,10$. El umbral convencional 0,5 corresponde a costos iguales.




Figura 2: PulpaLenga · costo medio por lote según umbral, con predicciones fuera de pliegue en entrenamiento + validación. La línea discontinua marca $t^* = 90/890$.

Tabla 5: PulpaLenga · prueba consultada una vez. Modelo y umbrales fijados antes de mirar la prueba.

	umbral	TP	FN	FP	recall	precision	costo total (miles CLP)
umbral fuera de pliegue	0.07	31.00	0.00	113.00	1.00	0.22	10170.00
umbral teórico t^*	0.10	24.00	7.00	85.00	0.77	0.22	13250.00
umbral 0,5	0.50	3.00	28.00	3.00	0.10	0.50	22670.00
inspeccionar todo	0.50	31.00	0.00	159.00	1.00	0.16	14310.00
no inspeccionar	0.50	0.00	31.00	0.00	0.00	0.00	24800.00

La cercanía del umbral elegido fuera de pliegue a t^* es compatible con esa regla de decisión, pero **no demuestra calibración**. Distintas distribuciones de probabilidades pueden tener el mismo umbral óptimo; se requieren diagramas de confiabilidad, puntajes probabilísticos y evaluación independiente. Elegir el umbral o comparar modelos **con la prueba** —como hacía la versión original del notebook de PulpaLenga— hace que el costo informado sea optimista, porque la prueba participó en la decisión.

8.2 Calibración

Un modelo está calibrado si, entre los casos con probabilidad estimada cercana a p , la frecuencia observada es cercana a p . Se revisa con un diagrama de confiabilidad y puntajes probabilísticos como Brier, que resume calidad probabilística y no aísla solo calibración. Ponderar clases puede alterar intercepto, coeficientes y orden; no garantiza una mera traslación del puntaje. Platt o isotónica buscan mejorar la escala y requieren evaluación independiente; un ensamble de calibración cruzada también puede modificar el orden [10], [11]. La regla t^* presupone probabilidades calibradas y la estructura de costos declarada.

8.3 Eventos raros

Con prevalencias bajas, accuracy es casi inútil y las métricas se vuelven inestables: con 30 fraudes en 1.200 transacciones, una prueba del 20% contendría unos seis casos. Conviene usar predicciones fuera de pliegue, intervalos bootstrap para AP y, sobre todo, más casos etiquetados y mejores variables. Ponderar clases cambia el umbral efectivo; no crea información.

9 Limitaciones, estabilidad y gobierno del modelo

9.1 Dónde puede fallar un modelo

Limitación	Cómo se detecta	Respuesta
Desempeño desigual por grupo	Métricas y calibración por segmento con intervalos	Revisar datos del grupo, recalibrar o restringir el uso
Inestabilidad	Coefficientes y métricas bajo remuestreo bootstrap	No basar recomendaciones en efectos de signo incierto
Deriva	PSI de variables y del puntaje; tasa predicha frente a observada	Investigar la causa; recalibrar o reentrenar
Supuestos de costo inciertos	Sensibilidad del umbral a c_{FN}/c_{FP}	Acordar rangos con finanzas; elegir reglas robustas
Confusión entre predicción y causa	El modelo no identifica efectos de intervenciones	Pilotos con grupo de control

9.2 Estabilidad poblacional

El Population Stability Index compara la distribución de una variable entre una población de referencia (e_k) y una nueva (a_k) en tramos k :

$$\text{PSI} = \sum_k (a_k - e_k) \ln \frac{a_k}{e_k}.$$

Una convención habitual en riesgo de crédito —no un estándar universal— lee $\text{PSI} < 0,10$ como estable, $0,10-0,25$ como cambio moderado y $> 0,25$ como cambio significativo [8]. El PSI detecta cambios de distribución, no sus causas ni la pérdida de desempeño, que solo se mide cuando llegan etiquetas.

9.3 Riesgo de modelo y obligaciones

Como referencia internacional, la guía estadounidense SR 26-2 del 17 de abril de 2026 recomienda gestión proporcional al riesgo, desarrollo documentado, validación y seguimiento [12]. Reemplazó SR 11-7; esta última se conserva como antecedente histórico, no como referencia vigente. El alcance depende del tipo y tamaño de la entidad y del uso del modelo; esta guía de supervisión estadounidense no se convierte automáticamente en una obligación chilena.

En Chile, la edición de octubre de 2026 distingue el marco vigente de protección de datos y la transición general de la Ley 21.719 al **1 de diciembre de 2026** [13]. Al aplicar un caso, se debe comprobar la disposición y fecha que corresponden. Declarar finalidad, población, datos utilizados, medidas de protección y límites ayuda a evaluar el uso del modelo; revisar desempeño por grupos permite discutir consecuencias de priorizar o excluir personas.

10 Comunicación y mejora continua

10.1 Ficha del modelo

Una ficha del modelo (*model card*) documenta propósito, usos no permitidos, datos, variables, evaluación, limitaciones, monitoreo y responsables [14]. Es el insumo de un comité de riesgo y la memoria del proyecto. El notebook 06 la genera a partir de las cifras calculadas.

10.2 Mensajes por audiencia

La estructura **Situación–Complicación–Resolución** ordena el mensaje. Al directorio se le habla de decisión, impacto e incertidumbre; a una gerencia comercial, de umbral, alcance y supuestos de campaña; a un comité técnico, de métricas, validación, estabilidad y monitoreo. Siempre se declaran el horizonte, el conjunto en que se midió cada cifra y lo que el modelo no hace.

10.3 Recomendaciones de mejora

Cada recomendación responde a una limitación observada con **evidencia, acción y métrica de verificación**. «Mejorar el modelo» no es una recomendación; «recalibrar por región porque la probabilidad media difiere de la tasa observada, y verificar con Brier por región en el próximo trimestre» sí lo es.

10.4 Lectura crítica de informes

Un buen informe de modelo tiene resumen ejecutivo con cifras, fases CRISP-DM, criterios técnicos y de negocio y un umbral económico. Antes de tomarlo como referencia conviene revisar que el umbral se calibre fuera de la prueba, que se informe la incertidumbre, que se evalúe por segmento y que los datos y el código permitan reproducirlo. El notebook 06 aplica esa lista a un informe ficticio.

11 Profundización: pronóstico de series de tiempo

Una serie mensual combina tendencia, estacionalidad y ruido. Las referencias mínimas son el pronóstico **ingenuo** y el **ingenuo estacional**. Una regresión con tendencia lineal y meses como indicadores es un primer modelo interpretable; Holt-Winters y SARIMA son extensiones [15]. La evaluación usa **origen móvil**: con historia hasta T se pronostica $T + 1, \dots, T + h$ y se avanza. El MASE divide el MAE del método por el MAE del ingenuo estacional en la muestra de entrenamiento; $\text{MASE} < 1$ indica mejora [16]. Los intervalos empíricos por horizonte se calculan con errores de origen móvil y su cobertura se verifica en orígenes posteriores; con pocas observaciones tienden a ser estrechos.

12 Ejercicios resueltos y preguntas de discusión

1. Formulación. Una cadena de farmacias quiere «usar datos para el stock». Formula un problema predictivo. *Respuesta:* Y = unidades vendidas por producto y local en la próxima semana; unidad producto-local-semana; horizonte de una semana; decisión: reposición; métrica guía: MAE en unidades y sesgo, porque el quiebre de stock y el sobrestock tienen costos distintos. Variables: ventas rezagadas, promociones planificadas, estacionalidad.

2. Sesgo y varianza. Un árbol sin límite de profundidad logra $R^2 = 0,99$ en entrenamiento y $0,55$ en validación; una regresión lineal logra $0,80$ y $0,78$. *Respuesta:* el árbol tiene alta varianza (sobreajuste). Se prefiere la lineal o un árbol podado; la brecha entrenamiento-validación es la señal.

3. Razón de chances. En una logística, el coeficiente de «retrasos de pago» es $0,40$ por retraso. La probabilidad de abandono de un cliente es $0,25$. ¿Cuál es con un retraso más? *Respuesta:* chances = $0,25/0,75 = 1/3$; nuevas chances = $e^{0,40}/3 \approx 0,497$; probabilidad = $0,497/1,497 \approx 0,33$.

4. Métricas. Con $VP = 30$, $FP = 20$, $FN = 10$ y $VN = 140$: accuracy = $170/200 = 0,85$; precisión = $30/50 = 0,60$; recall = $30/40 = 0,75$; $F_1 = 2(0,6)(0,75)/1,35 \approx 0,667$. Con $c_{FN} = 5$ y $c_{FP} = 1$, el costo medio es $(5 \cdot 10 + 20)/200 = 0,35$.

5. Umbral óptimo. Un falso negativo de fraude cuesta 200 mil CLP y bloquear una transacción legítima, 10 mil. *Respuesta:* $t^* = 10/210 \approx 0,048$: con probabilidades calibradas, conviene revisar toda transacción con riesgo superior a $4,8\%$. Si la capacidad del equipo de revisión es limitada, el umbral efectivo lo fija esa restricción.

6. Calibración. Un modelo tiene AUC $0,85$ y entre los clientes con probabilidad estimada $0,40$ abandona el 20% . *Respuesta:* ordena bien pero sobrestima: no es correcto comunicar «riesgo de 40% ». Se recalibra (Platt o isotónica) con validación cruzada y se verifica con el puntaje de Brier.

7. Validación temporal. ¿Por qué no usar validación cruzada aleatoria para pronosticar ventas mensuales? *Respuesta:* porque se entrenaría con meses posteriores a los que se pronostican: el error estimado sería optimista. Se usa origen móvil.

8. PSI. Un tramo pasa de 20% a 30% de la población. Su contribución al PSI es $(0,30 - 0,20) \ln(0,30/0,20) \approx 0,041$. Si otros tramos aportan $0,08$ en total, el PSI de $0,121$ indica cambio moderado: se investiga la causa antes de recalibrar.

9. Discusión. Un modelo de abandono mejora cuando incluye «región». ¿Es aceptable usarlo para decidir a quién ofrecer un beneficio? *Orientación:* depende de la finalidad, de si la región actúa como sustituto de una característica protegida y de la calibración por grupo; la decisión requiere revisión ética y documentación.

10. Discusión. El informe de un proveedor reporta AUC 0,95 «en datos de prueba» y un umbral optimizado. ¿Qué preguntas harías? *Orientación:* ¿cómo se particionó? ¿Se eligieron modelo y umbral sin la prueba? ¿Hay variables posteriores al evento? ¿Cuál es la línea base? ¿Cómo varía por segmento y en el tiempo?

13 Rúbrica formativa y ruta de doce semanas

13.1 Rúbrica formativa de un proyecto predictivo

Dimensión	Logrado	En desarrollo	Inicial
Formulación (CE 1.2–1.3, 2.1)	Y, unidad, horizonte, decisión y costos explícitos	Falta un elemento	Problema vago o sin decisión
Datos y preparación (CE 2.1–2.2)	Contrato, mecanismos de vacíos y pipeline sin fugas	Preparación correcta sin documentar	Preparación fuera del pipeline o con fugas
Modelamiento (CE 2.3–2.4)	Línea base, al menos dos familias y validación adecuada	Un modelo con validación	Sin línea base ni validación
Evaluación (CE 3.1–3.2)	Métricas pertinentes, umbral por costo, prueba consultada una vez	Métricas correctas sin umbral económico	Solo accuracy o evaluación en entrenamiento
Limitaciones y mejoras (CE 3.3, 3.5)	Segmentos, estabilidad y recomendaciones verificables	Limitaciones genéricas	Sin análisis crítico
Comunicación (CE 1.4, 3.4)	Mensaje por audiencia con incertidumbre y ficha	Mensaje claro sin incertidumbre	Jerga sin decisión

La rúbrica es formativa: no reemplaza las ponderaciones ni los instrumentos institucionales vigentes.

13.2 Ruta sugerida

Semana	Unidad	Tema	Recurso principal
1	U1	Problema predictivo, error reducible e irreducible	Notebook 01 · guía cap. 1
2	U1	Técnicas, aplicaciones, límites y fuga	Notebook 01 · guía cap. 2
3	U2	CRISP-DM, calidad de datos y pipeline	Notebook 02 · guía cap. 3
4	U2	Regresión múltiple y estacionalidad	Notebook 03 · guía cap. 4
5	U2	Clasificación: logística, árboles, KNN y bosques	Notebook 04 · guía cap. 5
6	U2	Regularización y modelos no lineales	Notebook 03 · guía cap. 6

Semana	Unidad	Tema	Recurso principal
7	U2	Validación cruzada e hiperparámetros	Notebook 05 · guía cap. 7
8	U3	Métricas de regresión y clasificación · laboratorio S8	Notebook 05 · guía cap. 8
9	U3	Curvas ROC/PR, umbral y costos	Notebook 05 · guía cap. 9
10	U3	Calibración, eventos raros y prueba final	Notebook 05 · guía cap. 9
11	U3	Limitaciones, estabilidad, deriva y riesgo de modelo	Notebook 06 · guía cap. 10
12	U3	Ficha del modelo, recomendaciones y comunicación	Notebook 06 · guía cap. 11
Profundización	—	Pronóstico de series de tiempo	Notebook 07 · guía cap. 16

14 Glosario

Término	Definición
AP (precisión promedio)	Resumen de la curva precisión–recall; su referencia es la prevalencia
AUC	Probabilidad de que un positivo reciba mayor puntaje que un negativo
Brier	Error cuadrático medio de las probabilidades estimadas
Calibración	Concordancia entre probabilidades estimadas y frecuencias observadas
Deriva	Cambio en la distribución de las variables o en la relación con el resultado
Fuga de información	Uso de datos no disponibles al momento de decidir
Gini	$2 \text{ AUC} - 1$ en el contexto de puntajes de riesgo
Hiperparámetro	Parámetro fijado antes de entrenar que controla la complejidad
KS	Máxima distancia entre distribuciones acumuladas de puntaje de positivos y negativos
Línea base	Regla simple que un modelo debe superar
MASE	Error absoluto escalado por el ingenuo estacional
PSI	Índice de estabilidad poblacional
Razón de chances	Factor multiplicativo de las chances por unidad de una variable
Regularización	Penalización de coeficientes para reducir varianza

Término	Definición
Umbral	Punto de corte que convierte probabilidades en acciones
Validación cruzada	Rotación de pliegues para estimar el desempeño con su variabilidad

Referencias

Bibliografía

- [1] scikit-learn developers, «Common pitfalls and recommended practices». Accedido: 8 de octubre de 2026. [En línea]. Disponible en: https://scikit-learn.org/stable/common_pitfalls.html
- [2] G. James, D. Witten, T. Hastie, R. Tibshirani, y J. Taylor, *An Introduction to Statistical Learning: with Applications in Python*. Springer, 2023. doi: 10.1007/978-3-031-38747-0.
- [3] G. Shmueli, P. C. Bruce, P. Gedeck, y N. R. Patel, *Data Mining for Business Analytics: Concepts, Techniques and Applications in Python*. Wiley, 2019.
- [4] P. Chapman *et al.*, «CRISP-DM 1.0: Step-by-Step Data Mining Guide», technical report, 2000.
- [5] T. Hastie, R. Tibshirani, y J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2.^a ed. Springer, 2009. doi: 10.1007/978-0-387-84858-7.
- [6] A. N. Angelopoulos y S. Bates, «A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification», *arXiv preprint*, 2021, [En línea]. Disponible en: <https://arxiv.org/abs/2107.07511>
- [7] T. Saito y M. Rehmsmeier, «The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets», *PLOS ONE*, vol. 10, n.º 3, p. e0118432, 2015, doi: 10.1371/journal.pone.0118432.
- [8] N. Siddiqi, *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. Wiley, 2006.
- [9] C. Elkan, «The Foundations of Cost-Sensitive Learning», en *Proceedings of the 17th International Joint Conference on Artificial Intelligence (IJCAI)*, 2001, pp. 973-978.
- [10] A. Niculescu-Mizil y R. Caruana, «Predicting Good Probabilities with Supervised Learning», en *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, 2005, pp. 625-632. doi: 10.1145/1102351.1102430.
- [11] scikit-learn developers, «Probability calibration». Accedido: 8 de octubre de 2026. [En línea]. Disponible en: <https://scikit-learn.org/stable/modules/calibration.html>
- [12] Board of Governors of the Federal Reserve System, OCC and FDIC, «SR 26-2: Revised Guidance on Model Risk Management». Accedido: 9 de octubre de 2026. [En línea]. Disponible en: <https://www.federalreserve.gov/supervisionreg/srletters/SR2602.htm>
- [13] República de Chile, «Ley N.º 21.719, que regula la protección y el tratamiento de los datos personales y crea la Agencia de Protección de Datos Personales». Accedido: 9 de octubre de 2026. [En línea]. Disponible en: <https://www.bcn.cl/leychile/Navegar?idNorma=1209272>
- [14] M. Mitchell *et al.*, «Model Cards for Model Reporting», en *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*, 2019, pp. 220-229. doi: 10.1145/3287560.3287596.
- [15] R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.^a ed. OTexts, 2021. [En línea]. Disponible en: <https://otexts.com/fpp3/>
- [16] R. J. Hyndman y A. B. Koehler, «Another look at measures of forecast accuracy», *International Journal of Forecasting*, vol. 22, n.º 4, pp. 679-688, 2006, doi: 10.1016/j.ijforecast.2006.03.001.